

# 基于注意力的多尺度残差 U-Net 的海洋中尺度涡检测\*

王丽娜<sup>1,2</sup> 孙 阳<sup>3</sup> 张红春<sup>1</sup> 王旭东<sup>3</sup> 董昌明<sup>2,4</sup>

(1. 南京信息工程大学人工智能学院(未来技术学院) 江苏南京 210044; 2. 南方海洋科学与工程广东省实验室(珠海) 广东珠海 519080; 3. 南京信息工程大学计算机学院 江苏南京 210044; 4. 南京信息工程大学海洋科学学院 江苏南京 210044)

**摘要** 海洋中尺度涡是一类重要的海洋现象,其特征是海洋中的螺旋运动,伴随着海水温度、营养物质以及能量的输送,对海洋生态系统和全球的气候变化起着重要影响。因此,海洋涡旋的智能识别成为海洋学的研究热点之一。由于海洋中尺度涡数量众多且大小不同,存在检测精度不高问题。为了提高海洋中尺度涡的检测精度,提出一种基于注意力的多尺度残差 U-Net 的海洋涡旋检测模型(dual cross-attention- pyramid spilt attention-Res U-Net, DCA-PRUNet)。该模型采用基于注意力的编解码器结构。编解码器结构中,引入金字塔分割注意力(pyramid spilt attention, PSA)以提取多尺度特征,并捕获不同涡旋的特征信息;此外,为了解决网络过深导致模型无法训练的问题,引入残差学习模块。同时,为了使解码器更好地恢复涡旋细节信息,引入双交叉注意力模块(dual cross-attention, DCA)捕获编码器各个阶段的特征依赖。选取西北太平洋海域的海平面异常(sea level anomaly, SLA)与海面温度(sea surface temperature, SST)数据进行建模,实验结果表明 DCA-PRUNet 涡旋检测的准确率达到 95.12%,  $F_1$  分数达到 91.21%,显著优于现有的模型,验证了该模型的有效性。

**关键词** 海洋涡旋; 深度学习; 金字塔分割注意力; 残差学习; 双交叉注意力

**中图分类号** P731.16 **doi:** 10.11693/hyhz20240500106

海洋中尺度涡是一类重要的海洋现象,与普通的海洋环流不同,其空间尺度从几十公里至几百公里,垂直深度可深至海底(Dong *et al*, 2009; Sinha *et al*, 2016; Siegelman *et al*, 2020; Martínez-Moreno *et al*, 2021; Sun *et al*, 2021)。由于中尺度涡自身携带强大的动能,并具有分布广和跨度幅度较大特性,其对全球海洋的热量、盐分、生物和海水化学元素的运输起着重要的作用(Dong *et al*, 2014; Moreau *et al*, 2017; Resplandy *et al*, 2019; Zhang *et al*, 2019; Dai *et al*, 2020)。因此,海洋中尺度涡的检测成为了海洋学研究的热点问题之一(Lin *et al*, 2015)。

传统的涡旋检测方法分为三类:基于物理特征的

检测方法、基于几何轮廓特征的检测方法和基于物理特征与几何轮廓特征混合的检测方法。基于物理特征的 Okubo-Weiss 参数方法应用较广泛(Okubo, 1970; Weiss, 1991),该方法根据中尺度涡的物理特性,通过海平面异常(sea level anomaly, SLA)梯度计算地转关系识别涡旋,但其对有关物理参数的选取依赖人的主观因素,导致涡旋检测的准确性不高。基于几何轮廓特征的 Winding-Angle 方法,该方法基于流场的几何特征,通过提取涡旋运动的封闭环状的流线,并进行聚类达到涡旋检测的目的(Portela, 1997)。Chaigneau 等(2008)提出的方法研究南太平洋东部海洋的海洋涡旋检测,将基于海面高度(sea surface height, SSH)场中识

\*南方海洋科学与工程广东省实验室(珠海)资助项目, SML2020SP007 号;国家重点研发项目, 2023YFC3008204 号。王丽娜, 副教授, 博士, E-mail: wangln@nuist.edu.cn

收稿日期: 2024-05-05, 收修改稿日期: 2024-07-10

别出的极值作为涡旋的涡心、粒子的运动轨迹作为流线,同时采用 Winding-Angle 方法选出封闭流线,确定涡旋边界,提高检测准确率,但该方法计算较复杂,影响涡旋检测效率。Dong 等(2011)将海面温度(sea surface temperature, SST)作为数据集,利用海洋涡旋的几何特征来检测涡旋。由于物理特征方法、几何轮廓特征方法存在涡旋检测的不足,有研究者提出利用物理特征与几何轮廓特征相互融合的方法来检测涡旋。例如 Yi 等(2014)提出了一种混合检测算法,该混合检测算法将 Okubo-Weiss 参数方法与基于 SSH 的方法相结合,通过物理参数  $W$  标准和 SLA 局部极值来检测涡流中心,并使用 SLA 轮廓给出涡流的尺寸。该方法融合了各子算法的优点,但数据需要经过多次预处理消除噪声,并需要海洋专家的帮助,检测的效率与准确性有待提高。

近年来,随着深度学习的广泛应用,已有一些基于深度学习的方法应用到涡旋检测,将涡旋检测转化为深度学习中图像的语义分割问题,完成海洋涡旋的检测(Xu *et al.*, 2021)。Lguensat 等(2018)提出了 EddyNet 模型,该模型以 U-Net 为基础,缩减了编码器与解码器部分的卷积层,对南大西洋海域的 SSH 进行训练,实现了 SSH 图像的海洋涡旋自动检测(Ronneberger *et al.*, 2015),涡旋检测准确率为 89.92%。Liu 等(2020)利用多源遥感数据 SSH 与 SST,提出基于深度神经网络的自动涡旋检测算法,提高了涡旋检测的准确性和效率。随着语义分割模型在深度学习领域的不断改进,许多专家也尝试将语义分割模型应用于海洋涡旋检测。Xu 等(2019)将 PSPNet 模型(Zhao *et al.*, 2017)应用于海洋涡旋检测中,PSPNet 模型通过金字塔池化模块和扩张卷积模块,融合了不同尺度的特征,通过北太平洋海域的 SLA 数据进行训练,与通过速度场的几何特征来识别涡流的检测方法比较,PSPNet 模型有更优的涡旋检测性能。但模型中存在卷积与跨步池化,使得涡旋边界信息的检测不理想。芦旭熠等(2020)利用 SLA 数据,制作海洋涡旋样本,基于 YOLOv3 的算法进行涡旋检测,在研究区域  $17^{\circ}\sim 42^{\circ}\text{N}$ ,  $147^{\circ}\sim 172^{\circ}\text{W}$  上涡旋的检测精确率达到 93%。同时 Redmon 等(2018)实现了涡旋时空特征的可视化。Santana 等(2020)提出不同的网络结构检测 SSH 图像中的涡旋类别,该模型对 U-Net 网络进行优化改进,进一步减少了参数量,但模型的特征提取能力不强。董子意等(2022)将残差(He *et al.*, 2020)与卷积注意力(Woo *et al.*, 2018)引入 U-Net 中,以南大西洋的卫星海面数据集为例,中尺度涡检测

准确率达到 93.28%,实现了海洋涡旋的自动检测。Zhao 等(2023)将金字塔分割注意力(pyramid spilt attention, PSA)(Zhang *et al.*, 2022a)与 U-Net 相结合的涡旋识别模型 PSA-EDUNet,融合 SLA 和 SST,能够有效提取多个尺度的涡旋信息,在黑潮延伸区的检测准确率为 94.06%,但该模型忽略了编码器特征之间的通道和空间依赖,使得编码器与解码器之间存在语义差异。

为了提高海洋中尺度涡的检测精度,本文提出一种基于改进 U-Net 的高效涡旋检测模型(dual cross-attention-pyramid spilt attention-Res U-Net, DCA-PRUNet)。通过在编解码之间的跳跃连接上添加双交叉注意力(dual cross-attention, DCA),减少编码器与解码器之间的语义差距,使模型关注不同尺度涡旋的轮廓信息;引入金字塔分割注意力提取不同尺度的涡旋特征信息,进一步提升检测精度;将编码器与解码器的卷积块用残差块代替,进行更深层次的训练,避免梯度消失,极大地提升了涡旋的检测性能。

## 1 数据与标签

### 1.1 研究区域与数据

根据旋转方向,涡流传统上分为气旋涡和反气旋涡,对应负的和正的 SLA。此外,由于地球的自转,气旋涡旋(反气旋涡旋)使得海面海水辐散(辐聚),从而引起了下层(上层)海水上升(下降)以作为补充,进而使海面呈现出低(高)的 SST (Zhang *et al.*, 2022b)。因此,海洋涡旋的不同特征可以从 SLA 和 SST 中识别。本文将海平面异常 SLA 和海面温度 SST 作为输入数据集,使得模型能充分学习涡旋的特征信息。SLA 是测量的海面高度与平均海面高度值的差值,由哥白尼海洋环境检测服务中心(Copernicus Marine Environment Monitoring Service, CMEMS)提供。时间分辨率为 1 d,空间分辨率为  $0.25^{\circ}\times 0.25^{\circ}$ 。

SST 是海洋表层的海水温度,它是美国国家海洋和大气管理局(National Oceanic and Atmospheric Administration, NOAA)提供的最佳内插海面温度 OISST 产品,时间分辨率为 1 d,空间分辨率为  $0.25^{\circ}\times 0.25^{\circ}$ 。

所提的实验涡旋检测方案在西北太平洋海域经纬度跨度  $56^{\circ}$  的区域,纬度范围为  $0^{\circ}\sim 56^{\circ}\text{N}$ ,经度范围为  $120^{\circ}\sim 176^{\circ}\text{E}$ 。西北太平洋区域的 SLA 总体呈现增长趋势,SLA 呈明显年际变化规律,上半年 SLA 比较低,下半年 SLA 比较高。SLA 既受到全球变暖的影

响,又与厄尔尼诺-南方涛动现象(El Niño-Southern Oscillation, ENSO)相关。本文选取西北太平洋海域 2004~2018 年共 15 a 的 SLA 和 SST 数据集,其中 2004~2017 年的 5 114 张图像作为训练集,2018 年的 365 张图像作为测试集。

## 1.2 涡旋标签构建

选取基于卫星高度计的海洋涡旋识别追踪数据集,构建模型训练所需涡旋的标签。该数据来自 CASEarth 官网的地球大数据科学工程项目(big earth data science engineering project),数据格式为 JSON。该数据集的特征信息通过以下步骤获取:首先将全球 SLA 图进行划分,对每个划分出的 SLA 图进行空间高通滤波,在每个 SLA 区域内寻找局部极小值(或极大值),并指定这些极值所在像素为潜在的涡旋,计算和搜索 SLA 轮廓线,提取涡流边界,最后将各 SLA 图的涡旋识别结果合并,得到每天全球涡旋类别、涡旋中心的经纬度、涡旋轮廓经纬度和涡旋半径等特征(Liu *et al.*, 2016)。由于 SST 与 SLA 数据的空间分辨率为  $0.25^\circ \times 0.25^\circ$ ,全球经纬度范围为  $-90^\circ \sim 90^\circ, -180^\circ \sim 180^\circ$ ,全球像素点所对应的矩阵范围为  $[180/0.25, 360/0.25]$ ,即  $[720, 1440]$ 。构建涡旋标签的处理流程如图 1 所示。

第一步,去除数据集中涡旋轮廓信息为空的涡旋,




图 1 涡旋标签构建流程图

Fig.1 Flow chart of eddy labeling

并提取涡旋的类别和轮廓经纬度信息;第二步,为了构造全球的涡旋标签,需要构造一个  $720 \times 1440$  大小的全“0”矩阵。接着分为两步处理,其一是确定涡旋的边缘轮廓区域,根据最近匹配原则将提取到的涡旋轮廓信息与最符合  $0.25^\circ$  分辨率的经度与纬度进行匹配,反演出经纬度对应的全球范围矩阵的坐标,若涡旋的类别为反气旋涡(anticyclonic eddy, AE),则将该像素点标记为 1,若涡旋的类别为气旋涡(cyclonic eddy, CE),则将该像素点标记为 2;其二是确定涡旋的内部区域,根据轮廓经纬度信息来确定涡旋经纬度阈值,将涡旋框在矩形框内,由于涡旋是不规则多边形,使用数学射线法来遍历矩形框内和边缘的点,由点引出一条射线,若射线与轮廓交点个数为奇数,则该点在涡旋内,若交点个数为偶数,则该点在涡旋外。遍历完成后,便确定了矩形内属于涡旋内部的点,依次根据涡旋类别对涡旋内部区域的点进行赋值,属于 AE 的像素点标记 1、属于 CE 的像素点标记 2。重复上述操作,由此得到一天的全球涡旋标签矩阵数据,其中 1 代表 AE 类别,2 代表 CE 类别,0 代表非涡旋类别。最后,根据实验的研究区域,对全球涡旋标签进行选取,得到研究海域的标签数据。模型训练需要的输出值和与模型识别结果比较的真值,通过选取研究海域的标签数据得到。

## 2 基于注意力的多尺度残差 U-Net 模型(DCA-PRUNet)

### 2.1 整体结构

在基于遥感影像的海洋涡旋检测任务中,受限与遥感影像的分辨率以及海洋涡旋本身的尺度特性,中小型涡旋往往呈现出较低的信噪比和复杂的背景干扰,极大地影响了涡旋检测的准确性。因此,如何有效地获取丰富的底层空间信息并减少采样过程中轮廓信息的丢失,成为了提高涡旋检测精度的核心问题。本文所提的基于注意力的多尺度残差 U-Net 模型 DCA-PRUNet 采用编码器-解码器结构,通过堆叠多个卷积层,能够学习到高级特征,其跳跃连接的设计使得网络在解码过程中能够捕获不同阶段编码块的依赖关系,能进一步提升涡旋及其轮廓信息的提取能力。该模型融合了金字塔分割注意力模块、双交叉注意力模块和残差学习模块,不仅有效地提取图像中的多尺度特征,还能通过注意力机制增强对重要信息的关注,并利用残差学习模型避免网络训练过程中的梯度消失问题。具体的网络结构如图 2 所示。






Fig.2 The structure of DCA-PRUNet

注: PSA 表示金字塔分割注意力模块; DCA 表示双交叉注意力模块;  $H$  表示图像高度;  $W$  表示图像宽度;  $C$  表示图像通道数; SLA 表示海平面异常; SST 表示海面温度

本文模型以 U-Net 网络为基础,左半部分为编码器,进行图像下采样操作,提取图像的特征信息,右半部分为解码器,通过上采样恢复特征图的细节和尺寸信息,编码器与解码器间添加双交叉注意力 DCA 的跳跃连接能捕获编码器特征间的通道依赖和空间依赖关系,还原图像精度。

编码器由 4 个编码块组成,由 SLA 和 SST 按通道拼接成的融合特征数据输入到编码器后,接连进入到 4 个编码块以生成层次特征。每个编码块包括负责特征学习的残差模块、金字塔分割注意力 PSA 模块和最大池化。在残差学习模块,首先把原始数据输入  $3 \times 3$  的卷积层,以及 ReLU 激活函数;接着再进入卷积核大小是  $3 \times 3$  的卷积层,输出的结果与原始输入计算残差,并经 ReLU 激活函数输出特征图。依次,将输出的特征图输入 PSA 模块获取多尺度特征信息,最后通过一个步长为 2、核大小为  $2 \times 2$  的最大池化层进行下采样。下采样后特征图的大小变为原来的  $1/2$ ,通道数为  $C$ ,第 1 个编码块输出的特征图的大小和通道数为  $(H/2) \times (W/2) \times C$ ,  $H$  表示图像高度,  $W$  表示图像宽度。在随后的 3 个编码块中,输出特征图的大小和通道数分别为  $(H/4) \times (W/4) \times C$ 、 $(H/8) \times (W/8) \times C$  和  $(H/16) \times (W/16) \times C$ 。

解码器由 4 个解码块组成。首先,每个解码块经过步长为 2、核大小为  $2 \times 2$  的转置卷积,上采样后,特征图的大小加倍。接着,将上采样得到的特征图和同一层编码块的特征图按通道进行拼接,得到通道数为  $2C$  的特征图。将拼接后的特征图输入到两个  $3 \times 3$  的卷积层,每个卷积层之后是 ReLU 激活函数层。与输入计算残差后,通过 ReLU 激活函数层输出,再进入 PSA 模块进行多尺度特征学习,使得通道数的大小恢

复为  $C$ 。每个解码块将特征图的大小扩大 1 倍而通道数不变,第 1 个解码块输出的特征图的大小为  $(H/8) \times (W/8) \times C$ 。在随后的 3 个解码块中,输出特征图的大小和通道分别为  $(H/4) \times (W/4) \times C$ 、 $(H/2) \times (W/2) \times C$  和  $H \times W \times C$ 。另外,在编码与解码同层之间的跳跃连接上增加双交叉注意力以提取多尺度编码器特征之间的通道和空间依赖,捕获涡旋更多细节信息。最后,通过核大小为  $1 \times 1$  的卷积层,将特征图通道的数量映射到实际分割预测类的数量,得到原始特征图的涡旋检测结果,本文最终输出的特征图尺寸为  $224 \times 224 \times 3$ 。

## 2.2 残差学习模块

随着深度学习模型网络层数的增加,梯度消失和网络性能退化的问题逐渐凸显,这严重制约了深度神经网络性能提升。为了解决这一问题,He 等(2020)提出了残差学习网络。该模型通过引入恒等映射路径,简化了网络的训练过程,并有效地提高了模型的检测精度。在编码器中,残差学习模块输入特征图的通道数为 2 (SLA+SST),经过两层的核大小为  $3 \times 3$  的卷积后,得到通道数为  $C$  的特征图。这样,输入前和卷积后的特征图维度不一致,导致应用跳跃连接使得两者不能相加,因此,选择  $1 \times 1$  的卷积核对输入进行升维,将其通道数变为  $C$ 。在解码器中,拼接后得到的特征图通道数为  $2C$ ,经过两层核大小为  $3 \times 3$  的卷积,特征图通道数变为  $C$ ,此时无法相加,应用  $1 \times 1$  的卷积核对输入进行降维,将其通道数变为  $C$ ,最后进行相加操作。残差学习结构图如图 3 所示。

残差学习模块由残差路径和核大小为  $1 \times 1$  的卷积块组成。其中,残差路径由两组核大小为  $3 \times 3$  的卷积层和 ReLU 激活函数构成。为了实现输入与残差路




图3 残差学习结构图

Fig.3 The structure of residual learning  
注: Conv 表示卷积层;ReLU 表示激活函数

径得到的特征图叠加,将模块的输入进行核大小为  $1 \times 1$  的卷积,然后与残差路径结果进行求和,再经过

ReLU 激活函数得到残差学习模块的输出。核大小为  $1 \times 1$  的卷积操作使得深层梯度在反向传播时可以直接传递到浅层,防止网络梯度消失,优化网络的训练过程,能进一步学习并提取新的特征,从而提升模型的表达能力。

### 2.3 金字塔分割注意力模块

金字塔分割注意力 PSA 通过增加涡旋的特征学习权重,减少背景非涡旋区域的学习权重,忽略无关信息,以获取更多的涡旋轮廓信息。PSA 模块是一种高效的注意力机制模块,同时考虑了通道交叉注意力和空间交叉注意力,能有效捕获不同尺度的空间信息达到丰富特征空间的目的。PSA 模块包括输入、压缩金字塔拼接(squeeze pyramid concat, SPC)模块、压缩激励(squeeze and excitation, SE)模块和输出 4 个部分,其结构图如图 4 所示。




图4 PSA 模块结构图

Fig.4 The structure of pyramid split attention module

注: SPC 表示压缩金字塔拼接;SE 表示压缩激励;softmax 表示归一化指数函数

残差学习模块输出的特征图用  $X$  表示,通道数为  $C$ 。SPC 模块首先将输入特征图等分为 4 个子块,随后每个子块上应用多尺度卷积以提取不同尺度特征的空间信息,SPC 结构如图 5 所示。

多尺度卷积的计算公式如式(1)所示。

$$F_i = \text{Conv}(k_i \times k_i, G_i)(X), i = 0, 1, 2, 3, \quad (1)$$

其中,  $k_i = 2 \times (i + 1) + 1$  表示第  $i$  子块使用的卷积核大小;  $G_i = 2^{\frac{k_i - 1}{2}}$  ( $i = 1, 2, 3$ ) 表示第  $i$  个子块的卷积组数,特殊地,  $G_0 = 1$ ;  $F_i \in R^{\frac{C \times H \times W}{4}}$  表示第  $i$  块的特征图。

经过多尺度卷积后,将各个子块的特征图在通道上拼接,即  $F = \text{Cat}([F_0, F_1, F_2, F_3])$ , 得到  $F \in R^{C \times H \times W}$ 。

为了获得不同通道特征图的注意力权值,将 SPC 模块的输出信息输入 SE 模块关注重要信息,使 PSA 模块输出像素级的注意力分数。SE 模块包括压缩和激励 2 个部分,压缩操作计算公式为:  $s_i =$

$\frac{1}{H \times W} \sum_{j=1}^H \sum_{k=1}^W F_i(j, k), i = 0, 1, 2, 3$ , 对每张特征图进行全局平均池化,并获得每个通道的全局特征。激励模块通过两层全连接,学习每个子块的特征图对应的通道权重,计算公式为:  $Z_i = \sigma[W_2 \delta(W_1 \times s_i)]$ ,  $i = 0, 1, 2, 3$ ,  $W_1$  和  $W_2$  是两层全连接的权重矩阵,  $\delta()$  表示 ReLU 激活函数,  $\sigma()$  表示 sigmoid 激活函数。通过 SE 模块能获取特征图通道之间的依赖关系。将 4 个子块的通道权重进行拼接,拼接后的结果为  $Z = Z_0 \oplus Z_1 \oplus Z_2 \oplus Z_3$ , 其中,  $\oplus$  代表向量拼接操作,  $Z$  表示得到的多尺度注意力权重。最后通过 Softmax 层进行归一化,实现局部和全局通道注意的交互,如式(2)所示。

$$\text{att}_i = \text{Softmax}(Z_i) = \frac{\exp(Z_i)}{\sum_{i=0}^3 \exp(Z_i)}. \quad (2)$$

将得到的各个通道注意进行拼接,得到整个通道注意向量,结果为  $\text{att} = \text{att}_0 \oplus \text{att}_1 \oplus \text{att}_2 \oplus \text{att}_3$ 。将多尺度




图 5 SPC 模块结构图

Fig.5 The structure of split and concat block

通道注意权重  $\text{att}_i$  与对应的特征图  $F_i$  相乘,得到多尺度通道特征图  $Y_i$ ,最后,将各个通道的特征图进行拼接,最后输出结果为  $\text{Out} = \text{Cat}([Y_0, Y_1, Y_2, Y_3])$ 。

#### 2.4 双交叉注意力模块

U-Net 网络在图像分割任务中取得了良好的性能,其通过跳跃连接将编码器提取到的低级特征连接到解码器,帮助模型恢复编码器下采样过程中的信息丢失。但随着网络的加深,编码器能提取到高级特征,但会忽略诸如涡旋轮廓的细节信息,编码器和解码器连接时会引起语义差距。为防止细节信息的丢失,本文在跳跃连接部分引入融合通道交叉注意力和空间交叉注意力的双交叉注意力模块 DCA,使得解码器更好地利用浅层特征,提高涡旋检测精度。DCA 将 4 个编码块中多尺度特征提取模块(PSA 模块的输出)作为输入,进行块编码后,通过通道交叉注意力和空间交叉注

意力捕获依赖关系,在每个交叉注意力模块后加入逐点求和层进行特征融合。最后经过批归一化层和 GeLU 激活函数层,连接到相应的解码器,其结构如图 6 所示。

由于每个编码块的多尺度特征提取模块输出特征图的大小不同,为方便使用交叉注意力,使用平均池化与  $1 \times 1$  的深度卷积,将  $1 \times 1 \times C$  的卷积核与对应  $C$  个通道的输入数据进行点乘,最后将结果相加,计算过程如式(3)所示。

$$T_i = \text{DConv1D} \{ \text{Reshape} [ \text{AvgPool2D}(E_i) ] \}, \quad (3)$$

其中,  $E_i \in R^{C \times \frac{H}{2^{i-1}} \times \frac{W}{2^{i-1}}}$  为第  $i$  阶段编码块的特征图,  $\text{AvgPool2D}(E_i)$  是对  $E_i$  进行平均池化,池化的核大小与步长均为  $2^{5-i}$ ,  $i=1,2,3,4$ 。  $\text{DConv1D}()$  为  $1 \times 1$  的深度卷积。  $T_i$  表示第  $i$  个编码序列。

通道交叉注意力关注各阶段编码块的特征图通道之




图 6 双交叉注意力模块

Fig.6 The dual cross-attention block

间的依赖关系,捕获通道之间的相关性,并重新分配权重,权重越大表示该通道的特征越重要,最后对各个通道的特征进行加权融合生成输出,其结构如图 7 所示。

首先对编码序列输入层归一化,沿通道将结果进行拼接(用来生成  $K$  和  $V$ ),使用  $1 \times 1$  的深度卷积用来生成  $Q_i$ 、 $K_c$  和  $V_c$ ,  $T_c = \text{Cat}([T_1, T_2, T_3, T_4])$ , 计算过程如式(4)所示。

$$\begin{aligned} Q_i &= \text{DConv1D}(T_i) \\ K_c &= \text{DConv1D}(T_c) \\ V_c &= \text{DConv1D}(T_c) \end{aligned} \quad (4)$$

由于通道交叉注意力是使用通道维度的注意力,所以要对  $Q_i$ 、 $K_c$  和  $V_c$  进行转置,通道交叉注意力的操作如式(5)所示。

$$\text{CCA}(Q_i, K_c, V_c) = \text{Softmax}\left(\frac{Q_i^T K_c}{\sqrt{C_c}}\right) V_c^T, \quad (5)$$




图 7 通道交叉注意力模块

Fig.7 The model of channel cross attention




图 8 空间交叉注意力模块

Fig.8 The model of spatial cross attention

其中,  $\frac{1}{\sqrt{C_c}}$  是缩放因子,特征通道权重的相似性通过

$Q_i$  和  $K_c$  得到。利用 Softmax 函数得到权重值,最后通过  $1 \times 1$  的深度卷积对输出进行投影,通过逐点求和层输出 4 个新的编码序列  $\bar{T}_1, \bar{T}_2, \bar{T}_3$  和  $\bar{T}_4$ 。

空间交叉注意力机制对编码块的特征图中重要的位置信息进行加权,如图 8 所示。

与通道交叉注意力不同,使用拼接后的结果生成  $Q_s$  和  $K_s$ ,使用归一化后的结果生成  $V_i$ ,  $\bar{T}_c = \text{Cat}([\bar{T}_1, \bar{T}_2, \bar{T}_3, \bar{T}_4])$  计算过程如式(6)所示。

$$\begin{aligned} Q_s &= \text{DConv1D}(\bar{T}_c) \\ K_s &= \text{DConv1D}(\bar{T}_c), \\ V_i &= \text{DConv1D}(\bar{T}_i) \end{aligned} \quad (6)$$

DConv1D() 为  $1 \times 1$  的深度卷积,空间交叉注意力



如式(7)所示。

$$\text{SCA}(Q_s, K_s, V_i) = \text{Softmax} \left( \frac{Q_s K_s^T}{\sqrt{d_k}} \right) V_i, \quad (7)$$

其中,  $\frac{1}{\sqrt{d_k}}$  为缩放因子, 对空间交叉注意力模块使用深度卷积得到 DCA 的输出, 最后, 逐点求和层进行特征融合, 经过批归一化层和 GeLU 激活函数层将输出连接到相应的解码块。

## 2.5 评价指标

涡旋提取本质上是图像中各个像素的分类问题, 即判断像素点属于非涡旋、气旋涡或反气旋涡, 将判断的结果与标签进行对比。选择准确率(accuracy,  $A$ )、查准率(precision,  $P$ )、查全率(recall,  $R$ )和  $F_1$  分数 4 个评价指标, 准确率  $A$  表示所有的预测像素点中, 预测正确的比例。查准率  $P$  表示预测正确的涡旋占所识别涡旋的比例。查全率  $R$  表示模型在所有真实涡旋样本中成功识别的比例。 $F_1$  分数为查准率与查全率两者的调和平均, 计算公式如下

$$A = \frac{TP + TN}{TP + TN + FP + FN}, \quad (8)$$

$$P = \frac{TP}{TP + FP}, \quad (9)$$

$$R = \frac{TP}{TP + FN}, \quad (10)$$

$$F_1 = \frac{2 \times P \times R}{P + R}. \quad (11)$$

上述公式中, TP 表示模型正确预测的涡旋数; TN 表示模型正确预测的非涡旋数; FP 表示模型预测的假涡旋数; FN 表示模型错误预测的非涡旋数。 $F_1$  分数可作为涡旋检测评价的依据。

## 3 实验与分析

### 3.1 实验设置

本文实验搭建主流的深度学习框架, GPU 为 NVIDIA GeForce RTX 3090, Python 版本为 3.9, CUDA 版本为 11.8, Pytorch 版本为 1.12。

选取 2004 年 1 月 1 日至 2017 年 12 月 31 日的 SST 与 SLA 作为训练集, 2018 年 1 月 1 日至 2018 年 12 月 31 日的 SST 与 SLA 数据作为测试集。SST 与 SLA 数据的空间分辨率均为  $0.25^\circ \times 0.25^\circ$ , 时间分辨率均为 1 d。首先需要对 SST 与 SLA 的缺失值、异常值进行处理, 为了提高模型训练效果, 对数据进行归一化处理, 如式(12)所示。

$$X_N = \frac{X - \min(X)}{\max(X) - \min(X)}, \quad (12)$$

其中,  $X_N$  是归一化后的样本,  $X$  是观测样本。 $\max()$  函数求解最大值,  $\min()$  函数求解最小值。

为使海洋涡旋检测模型获得最佳性能, 选择交叉熵为损失函数, 学习率为 0.001, 优化器选择 RMSprop, 对损失函数进行优化。输入数据的通道数  $C$  为 64, Batchsize 为 8, 迭代训练轮数为 200。同时, 金字塔分割注意力 PSA 卷积核大小分别为  $3 \times 3$ 、 $5 \times 5$ 、 $7 \times 7$  和  $9 \times 9$ 。对于双交叉注意力 DCA 模块, 通道注意力的注意力头数设置为 1, 空间注意力的注意力头数设置为 4。应用本文所提模型 DCA-PRUNet 在 SST 和 SLA 训练集上建立涡旋检测模型, 在测试集上完成测试, 并评估新模型的可行性和有效性。

### 3.2 DCA-PRUNet 及变体模型的性能比较

为了验证模型的可行性, 在参数设置相同的情况下, 基于不同技术点评估分别加入金字塔分割注意力 PSA、双交叉注意力 DCA 与残差的变体模型性能。表 1 展示了 U-Net 模型(Ronneberger *et al*, 2015)、PSA-UNet 模型(Zhao *et al*, 2023)、DCA-PUNet 模型(Ates *et al*, 2023)和本文所提的 DCA-PRUNet 模型在西北太平洋海域的涡旋检测性能。

表 1 DCA-PRUNet 及变体模型的涡旋检测性能

Tab.1 The eddy detection performance of DCA-PRUNet and its variant models

| 模型         | $A$     | $P$     | $R$     | $F_1$   |
|------------|---------|---------|---------|---------|
| U-Net      | 0.925 9 | 0.871 8 | 0.860 6 | 0.866 1 |
| PSA-UNet   | 0.938 9 | 0.875 7 | 0.865 2 | 0.870 4 |
| DCA-PUNet  | 0.946 3 | 0.904 7 | 0.893 7 | 0.899 1 |
| DCA-PRUNet | 0.951 2 | 0.919 7 | 0.904 8 | 0.912 1 |

注:  $A$  表示准确率;  $P$  表示查准率;  $R$  表示查全率;  $F_1$  表示查准率与查全率两者的调和平均

由表 1 可知, 本文模型准确率  $A$  达到 95.12%,  $F_1$  分数达到 91.21%。通过引入金字塔分割注意力模块、双交叉注意力模块和残差模块, 可以有效提取多尺度海洋涡旋特征, 提供了海洋涡旋的丰富底层细节信息, 各个模块均提升了模型涡旋检测性能。验证了该涡旋检测模型的可行性。

### 3.3 不同模型的性能比较

为了评估本文模型的涡旋检测性能, 选择 EddyNet 模型(Lguensat *et al*, 2018)、TBCNN 模型(Hang *et al*, 2022)、PSPNet 模型(Xu *et al*, 2019)、CBAM-RUNet 模型(董子意等, 2022)、PSA-EDUNet 模型(Zhao *et al*,



2023)和本文 DCA-PRUNet 模型进行性能分析。测试集上不同模型的实验结果如表 2 所示。

表 2 不同模型的涡旋检测性能

| 模型         | $A$     | $P$     | $R$     | $F_1$   |
|------------|---------|---------|---------|---------|
| EddyNet    | 0.917 4 | 0.874 1 | 0.818 4 | 0.845 3 |
| TBCNN      | 0.912 8 | 0.860 2 | 0.841 1 | 0.850 5 |
| PSPNet     | 0.933 4 | 0.854 2 | 0.862 3 | 0.858 2 |
| CBAM-RUNet | 0.925 1 | 0.877 7 | 0.851 6 | 0.864 4 |
| PSA-EDUNet | 0.940 6 | 0.887 2 | 0.886 2 | 0.886 7 |
| DCA-PRUNet | 0.951 2 | 0.919 7 | 0.904 8 | 0.912 1 |

从表 2 可知,本文所提出的 DCA-PRUNet 的准确率  $A$ 、查准率  $P$ 、查全率  $R$  和  $F_1$  分数均优于 EddyNet、TBCNN、PSPNet、CBAM-RUNet 和 PSA-EDUNet 模型,其在测试集上取得了 95.12% 的分类精度。EddyNet 与 TBCNN 的涡旋检测性能相近,PSPNet 与 CBAM-RUNet 的检测性能比 PSA-EDUNet 差。改进的模型引入了 PSA 模块、残差学习模块和 DCA 模块,通过 PSA 模块提取多尺度涡旋特征信息,残差学习模块避免训练时模型的退化和 DCA 模块解决编码器与解码器之间的语义差距,提高了涡旋检测精度,表明本文模

型涡旋检测的有效性。

涡旋半径是反映海洋涡旋的一个重要特征,也作为涡旋检测性能的评价指标。图 9 展示了在测试集上不同模型识别的海洋涡旋半径分布情况。

由图 9 可以看出,海洋涡旋半径分布不均,且大部分涡旋小于半径 100 km。对于不同检测模型而言,当涡旋半径小于 50 km 或大于 200 km 时,与其他模型比较,EddyNet 模型检测性能最差。TBCNN 在涡旋半径小于 100 km 或者大于 200 m 检测性能不佳,其他半径值的涡旋检测性能较优。PSPNet 在涡旋半径在 75~175 km 区间内检测性能较优,但在其他涡旋半径区间内检测性能欠佳。CBAM-RUNet 和 PSA-EDUNet 涡旋检测性能接近,本文模型 DCA-PRUNet 检测到的海洋涡旋数接近标签值,进一步验证了本文模型的有效性。

### 3.4 个例可视化

图 10 展示了不同涡旋检测模型在西北太平洋海域( $0^{\circ}\sim 56^{\circ}\text{N}$ ,  $120^{\circ}\sim 176^{\circ}\text{E}$ )2018 年 12 月 31 日得到的涡旋检测结果,其中,黄色为气旋涡,深青绿色为反气旋涡。Groundtruth 是通过 CASEarth 官网提供的涡旋数据集构建的涡旋标签数据,同时给出 SLA 和 SST 的分布。




图 9 不同模型识别的海洋涡旋半径分布

Fig.9 The radius distribution of oceanic eddies identified by different models

注: Groundtruth 表示涡旋标签数据;EddyNet、TBCNN、PSPNet、CBAM-RUNet、PSA-EDUNet 和 DCA-PRUNet 表示不同的涡旋检测模型

从图 10 中可以观测到海洋涡旋的数量较多,获取底层空间信息和轮廓信息是提升检测精度的关键。由于 EddyNet 和 TBCNN 在获取涡旋特征信息时采用固定尺寸的卷积核,不能挖掘海洋涡旋的细节信息,因此其对海洋涡旋的检测较差。而 PSPNet 中全局池化会损失一些细节信息,这使得海洋涡旋轮廓信息会丢失,

进而影响检测精度。CBAM-RUNet 经卷积注意力模块和残差学习模块捕获涡旋细节信息,PSA-EDUNet 通过 PSA 模块提取多尺度海洋涡旋信息,二者能够识别大多数海洋涡旋。与真实目标轮廓相比,本文 DCA-PRUNet 模型通过残差学习模块和 PSA 模块能提取多尺度涡旋的细节特征,同时 DCA 模块能有效




图 10 不同模型的涡旋检测结果

Fig.10 The eddy detection results of different models

注: a 中的黄色为气旋涡, 深青绿色为反气旋涡; SST 表示海面温度; SLA 表示海平面异常; Groundtruth 表示涡旋标签数据; EddyNet、TBCNN、PSPNet、CBAM-RUNet、PSA-EDUNet 和 DCA-PRUNet 表示不同的涡旋检测模型

利用上下文信息, 捕获更多涡旋的细节信息, 预测的目标轮廓与真实目标轮廓更加接近, 得到了几乎一致的结果。

统计图 10 个例的海洋涡旋检测结果, 给出不同模型检测的海洋涡旋数量如图 11 所示。由于 EddyNet 模型对涡旋提取能力不理想, 因此其检测到的涡旋数

量与标签之间存在一定的差距。TBCNN 模型对气旋涡存在误检情况, 同时对反气旋涡检测能力也不足。CBAM-RUNet 模型与 PSA-EDUNet 模型在涡旋数量的检测上较为接近, 表明二者在检测性能上相近。当采用本文模型时, 提取到的涡旋数量与标签最接近, 且误检率也相对较低, 为海洋涡旋检测提供了新的可能。




图 11 不同模型检测的海洋涡旋数量

Fig.11 The number of oceanic eddies detected by different models

注: Groundtruth 表示涡旋标签数据; EddyNet、TBCNN、PSPNet、CBAM-RUNet、PSA-EDUNet 和 DCA-PRUNet 表示不同的涡旋检测模型

## 4 结论

本文选择西北太平洋海域 2004 年 1 月至 2018 年 12 月期间的 SLA 和 SST 数据以及基于卫星高度计的海洋涡旋识别追踪数据集构建的涡旋标签数据作为训练集进行训练,并构建海洋中尺度涡检测模型,对得到的基于注意力的多尺度残差 U-Net 模型 DCA-PRUNet 分析其涡旋检测性能,得到以下主要结论:

(1) 本文利用准确率、查准率、查全率和  $F_1$  分数 4 个指标评价 DCA-PRUNet 模型的中尺度涡检测性能,将与其变体模型进行比较,结果表明 DCA-PRUNet 比变体模型涡旋检测精度高,验证了模型的可行性。

(2) 分析深度学习模型 EddyNet、TBCNN、PSPNet、CBAM-RUNet、PSA-EDUNet 和本文 DCA-PRUNet 模型的涡旋检测性能、海洋涡旋半径分布与个例可视化结果,表明本文模型提高了海洋中尺度涡的检测精度,验证了模型的有效性。

(3) 未来的涡旋检测工作应考虑涡旋变化的动态特性,以进一步提高涡旋检测精度。

(作者声明本文符合出版伦理要求)

## 参 考 文 献

芦旭熠, 单桂华, 李观, 2020. 基于深度学习的海洋中尺度涡识别与可视化[J]. 计算机系统应用, 29(4): 65-75.  
董子意, 杜震洪, 吴森森, 等, 2022. 基于改进 U-Net 网络的海洋中尺度涡自动检测模型[J]. 海洋学报, 44(2): 123-131.  
ATES G C, MOHAN P, CELIK E, 2023. Dual cross-attention for medical image segmentation [J]. Engineering Applications

of Artificial Intelligence, 126: 107139.

CHAIGNEAU A, GIZOLME A, GRADOS C, 2008. Mesoscale eddies off Peru in altimeter records: Identification algorithms and eddy spatio-temporal patterns [J]. Progress in Oceanography, 79(2/3/4): 106-119.

DAI J, WANG H Z, ZHANG W M, *et al*, 2020. Observed spatiotemporal variation of three-dimensional structure and heat/salt transport of anticyclonic mesoscale eddy in Northwest Pacific [J]. Journal of Oceanology and Limnology, 38(6): 1654-1675.

DONG C M, MAVOR T, NENCIOLI F, *et al*, 2009. An oceanic cyclonic eddy on the lee side of Lanai Island, Hawai'i [J]. Journal of Geophysical Research: Oceans, 114(C10): C10008.

DONG C M, MCWILLIAMS J C, LIU Y, *et al*, 2014. Global heat and salt transports by eddy movement [J]. Nature Communications, 5(1): 3294.

DONG C M, NENCIOLI F, LIU Y, *et al*, 2011. An automated approach to detect oceanic eddies from satellite remotely sensed sea surface temperature data [J]. IEEE Geoscience and Remote Sensing Letters, 8(6): 1055-1059.

HANG R L, LI G, XUE M, *et al*, 2022. Identifying oceanic eddy with an edge-enhanced multiscale convolutional network [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 15: 9198-9207.

HE K M, ZHANG X Y, REN S Q, *et al*, 2020. Deep residual learning for image recognition [C]//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE: 770-778.

LGUENSAT R, SUN M, FABLET R, *et al*, 2018. EddyNet: A



- deep neural network for pixel-wise classification of oceanic eddies [C]//Proceedings of the IGARSS 2018-2018 IEEE International Geoscience and Remote Sensing Symposium. Valencia: IEEE: 1764-1767.
- LIN X Y, DONG C M, CHEN D K, *et al*, 2015. Three-dimensional properties of mesoscale eddies in the South China Sea based on eddy-resolving model output [J]. Deep Sea Research Part I: Oceanographic Research Papers, 99: 46-64.
- LIU Y J, CHEN G, SUN M, *et al*, 2016. A parallel SLA-based algorithm for global mesoscale eddy identification [J]. Journal of Atmospheric and Oceanic Technology, 33(12): 2743-2754.
- LIU Y J, LI X F, REN Y B, 2020. A deep learning model for oceanic mesoscale eddy detection based on Multi-Source remote sensing imagery [C]//Proceedings of the IGARSS 2020-2020 IEEE International Geoscience and Remote Sensing Symposium. Waikoloa: IEEE: 6762-6765.
- MARTÍNEZ-MORENO J, HOGG A M, ENGLAND M H, *et al*, 2021. Global changes in oceanic mesoscale currents over the satellite altimetry record [J]. Nature Climate Change, 11(5): 397-403.
- MOREAU S, PENNA A D, LLORT J, *et al*, 2017. Eddy-induced carbon transport across the Antarctic Circumpolar Current [J]. Global Biogeochemical Cycles, 31(9): 1368-1386.
- OKUBO A, 1970. Horizontal dispersion of floatable particles in the vicinity of velocity singularities such as convergences [J]. Deep Sea Research and Oceanographic Abstracts, 17(3): 445-454.
- PORTELA L M, 1997. Identification and characterization of vortices in the turbulent boundary layer [D]. California: Stanford University: 57-82.
- REDMON J, FARHADI A, 2018. YOLOv3: An incremental improvement [C]//Computer Vision and Pattern Recognition. Berlin/Heidelberg: Springer: 1804:1-6.
- RESPLANDY L, LÉVY M, MCGILLICUDDY JR D J, 2019. Effects of eddy-driven subduction on ocean biological carbon pump [J]. Global Biogeochemical Cycles, 33(8): 1071-1084.
- RONNEBERGER O, FISCHER P, BROX T, 2015. U-net: Convolutional networks for biomedical image segmentation [C]//Proceedings of the 18th International Conference on Medical Image Computing and Computer-Assisted Intervention-MICCAI 2015. Munich: Springer: 234-241.
- SANTANA O J, HERNÁNDEZ-SOSA D, MARTZ J, *et al*, 2020. Neural network training for the detection and classification of oceanic mesoscale eddies [J]. Remote Sensing, 12(16): 2625.
- SIEGELMAN L, KLEIN P, RIVIÈRE P, *et al*, 2020. Enhanced upward heat transport at deep submesoscale ocean fronts [J]. Nature Geoscience, 13(1): 50-55.
- SINHA A, ABERNATHEY R P, 2016. Time scales of southern Ocean eddy equilibration [J]. Journal of Physical Oceanography, 46(9): 2785-2805.
- SUN W J, YANG J S, TAN W, *et al*, 2021. Eddy diffusivity and coherent mesoscale eddy analysis in the Southern Ocean [J]. Acta Oceanologica Sinica, 40(10): 1-16.
- WEISS J, 1991. The dynamics of enstrophy transfer in two-dimensional hydrodynamics [J]. Physica D: Nonlinear Phenomena, 48(2/3): 273-294.
- WOO S, PARK J, LEE J Y, *et al*, 2018. CBAM: Convolutional block attention module [C]//Proceedings of the 15th European Conference on Computer Vision-ECCV 2018. Munich: Springer: 3-19.
- XU G J, CHENG C, YANG W X, *et al*, 2019. Oceanic eddy identification using an AI scheme [J]. Remote Sensing, 11(11): 1349.
- XU G J, XIE W H, DONG C M, *et al*, 2021. Application of three deep learning schemes into oceanic eddy detection [J]. Frontiers in Marine Science, 8: 672334.
- YI J, DU Y, HE Z, *et al*, 2014. Enhancing the accuracy of automatic eddy detection and the capability of recognizing the multi-core structures from maps of sea level anomaly [J]. Ocean Science, 10(1): 39-48.
- ZHANG H F, HUANG B X, CHEN G, *et al*, 2022b. An efficient oceanic eddy identification method with XBT data using transformer [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 15: 9860-9872.
- ZHANG X Z, MA X H, WU L X, 2019. Effect of mesoscale oceanic eddies on extratropical cyclogenesis: A tracking approach [J]. Journal of Geophysical Research: Atmospheres, 124(12): 6411-6422.
- ZHANG H, ZU K K, LU J, *et al*, 2022a. EPSANet: An efficient pyramid squeeze attention block on convolutional neural network [C]//Proceedings of the 16th Asian Conference on Computer Vision-ACCV 2022. Macau, China: Springer: 1161-1177.
- ZHAO H S, SHI J P, QI X J, *et al*, 2017. Pyramid scene parsing network [C]//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE: 6230-6239.
- ZHAO N, HUANG B X, YANG J, *et al*, 2023. Oceanic eddy identification using pyramid split attention U-Net with remote sensing imagery [J]. IEEE Geoscience and Remote Sensing Letters, 20: 1500605.



## A MULTI-SCALE ATTENTION RESIDUAL-BASED U-NET MODEL FOR DETECTION OF OCEAN MESOSCALE EDDIES

WANG Li-Na<sup>1,2</sup>, SUN Yang<sup>3</sup>, ZHANG Hong-Chun<sup>1</sup>, WANG Xu-Dong<sup>3</sup>, DONG Chang-Ming<sup>2,4</sup>

(1. School of Artificial Intelligence (School of Future Technology), Nanjing University of Information Science and Technology, Nanjing 210044, China; 2. Southern Marine Science and Engineering Guangdong Laboratory (Zhuhai), Zhuhai 519080, China; 3. School of Computer Science, Nanjing University of Information Science and Technology, Nanjing 210044, China; 4. School of Marine Sciences, Nanjing University of Information Science and Technology, Nanjing 210044, China)

**Abstract** The mesoscale eddies in the ocean is an important ocean phenomenon, which is characterized by the spiral movement in the ocean; with the transportation of seawater temperature, nutrients, and energy, it has an important impact on marine ecosystems and global climate change. Therefore, intelligent identification of ocean eddies has become one of the research hotspots in oceanography. Due to the large number of mesoscale eddies in the ocean and their different sizes, there is a problem of low detection accuracy. To improve the detection accuracy of mesoscale eddies in the ocean, a novel model, the dual cross-attention- pyramid spilt attention-Res U-Net (DCA-PRUNet), was proposed for ocean eddy detection. The model adopts an attention-based encoder-decoder structure, in which the pyramid spilt attention (PSA) is introduced to extract multi-scale features and capture the characteristic information of different eddies. In addition, to solve the problem that the model cannot be trained due to the network layers being too deep, a residual learning module is incorporated. At the same time, to enable the decoder to better restore the eddy details, a dual cross-attention module (DCA) is combined to capture the feature dependencies in each stage of the encoder. Sea level anomaly (SLA) and sea surface temperature (SST) data in the NW Pacific Ocean were selected for modeling. The experimental results show that the accuracy of DCA-PRUNet eddy detection reached 95.12% with  $F_1$  score of 91.21%, which is significantly better than the existing models, verifying the effectiveness of the novel model.

**Key words** ocean eddy; deep learning; pyramid split attention; residual learning; dual cross-attention